

Sistema de Analisis de Riesgo Crediticio mediante Machine Learning y Modelos de Lenguaje

Clasificacion automatica de solicitudes bancarias con XGBoost e interpretacion narrativa con Llama 3.1 via Groq API

Tomas Echavarria Santiago Sanchez
techavarrg@eafit.edu.co ssanchezXX@eafit.edu.co

Nathan Martinez
nmartinezXX@eafit.edu.co

Escuela de Ciencias Aplicadas e Ingenieria . Universidad EAFIT
Curso: Inteligencia Artificial . Semestre 2026-1
Entrega: 19 al 22 de mayo de 2026

Repositorio: github.com/tomechava/proyecto-ia-eafit
App desplegada: proyecto-ia-eafit-2026-1.streamlit.app

Resumen

Contexto: La evaluacion del riesgo crediticio es un problema central en la industria financiera; la capacidad de predecir el incumplimiento de pagos de manera precisa y explicable reduce perdidas y mejora la equidad en el acceso al credito. **Objetivo:** Construir un sistema completo que clasifique solicitudes de credito en tres niveles de riesgo (bajo, medio y alto) y genere reportes narrativos comprensibles para analistas financieros. **Metodo:** Se entrenaron cuatro modelos de clasificacion supervisada sobre el German Credit Risk dataset (UCI, $N = 1,000$) y se selecciono XGBoost como modelo final por su superior capacidad discriminativa. La salida cuantitativa del modelo se integra con Llama 3.1 8B via Groq API para producir explicaciones en lenguaje natural mediante prompting estructurado con rol de analista experto. **Resultados:** El modelo XGBoost alcanzo $AUC = 0,767$, $Accuracy = 0,733$ y $F1 \text{ Macro} = 0,546$ en el conjunto de prueba. **Conclusion:** El sistema demuestra que la combinacion de modelos de aprendizaje automatico con modelos de lenguaje de gran escala produce herramientas de apoyo a la decision mas interpretables que los enfoques tradicionales, con potencial directo de aplicacion en entidades bancarias de la region.

Palabras clave: Machine Learning, XGBoost, LLM, Riesgo Crediticio, Explicabilidad, Groq, German Credit.

1. Introduccion

El acceso al credito es un mecanismo fundamental para el desarrollo economico; sin embargo, el incumplimiento de obligaciones financieras representa una amenaza persistente para la estabilidad de las entidades bancarias. Los sistemas tradicionales de evaluacion crediticia dependen de reglas estaticas y puntuaciones de credito que no capturan la complejidad de los perfiles de riesgo modernos ni

proveen explicaciones comprensibles para los solicitantes.

Este proyecto aborda la siguiente pregunta de investigacion:

“¿Puede un modelo de clasificacion supervisada sobre el German Credit Risk dataset superar a una linea base logistica en AUC con un margen significativo, y puede un componente LLM transformar esa prediccion numerica en un reporte narrativo accionable para un analista financiero?”

Para responderla, se construyo un pipeline completo que abarca exploracion de datos, preprocesamiento, entrenamiento comparativo de cuatro modelos, evaluacion rigurosa y despliegue en una aplicacion interactiva. El componente de lenguaje natural utiliza el modelo Llama 3.1 8B disponible de forma gratuita a traves de la API de Groq, lo que hace el sistema reproducible sin costo computacional adicional.

El documento se organiza de la siguiente manera: la Seccion 2 describe el dataset y los hallazgos del EDA; la Seccion 3 presenta la arquitectura del sistema; la Seccion 4 detalla la metodologia experimental; la Seccion 5 reporta los resultados; la Seccion 6 discute limitaciones y extensiones; y la Seccion 7 concluye el trabajo.

2. Datos y Exploracion

2.1. Descripción del dataset

Cuadro 1: Resumen del dataset utilizado

Atributo	Descripción
Fuente	UCI / Kaggle (Statlog)
Registros (N)	1,000 solicitudes
Features originales	6 numericas / 4 categoricas
Features tras encoding	19 columnas
Variable objetivo	Risk: binaria good (70 %) / bad (30 %)
Periodo	Dataset clasico, version 2016
Tamaño en disco	≈ 60 KB

El dataset describe solicitudes de credito del sistema bancario aleman con nueve atributos originales: edad, sexo, nivel de trabajo, tipo de vivienda, estado de la cuenta de ahorros, estado de la cuenta corriente, monto del credito solicitado, duracion en meses y proposito del credito.

2.2. Hallazgos del analisis exploratorio

Distribucion de la variable objetivo. El dataset presenta un desbalance moderado de 70 % / 30 % a favor de la clase **good**. Este desbalance es suficiente para sesgar modelos que optimizan accuracy directamente, por lo que se adopto AUC como metrica principal y se aplico ponderacion de clases durante el entrenamiento.

Valores nulos. Se identificaron 183 valores faltantes en **Saving accounts** (18.3 %) y 394 en **Checking account** (39.4 %). Ambas variables son ordinales con categorias significativas (little, moderate, quite rich, rich); los valores faltantes se interpretaron como una categoria adicional denominada **unknown**, incorporada al **OrdinalEncoder** durante el preprocesamiento.

Correlaciones con el target. Las variables con mayor poder discriminativo identificadas durante el EDA fueron: el estado de la **Checking account** (clientes sin cuenta corriente presentan tasas de incumplimiento notablemente superiores), la **Duration** del credito (duraciones superiores a 24 meses incrementan el riesgo) y el **Credit amount** (montos superiores a 5,000 USD correlacionan con mayor riesgo). Estas observaciones fueron confirmadas posteriormente por la importancia de variables del modelo XGBoost.

Proposito del credito. El 34 % de las solicitudes corresponde a vehiculos y el 28 % a equipos de entretenimiento. Los prestamos para reparaciones y negocios, aunque menos frecuentes, presentan tasas de incumplimiento proporcionalmente mayores.




Figura 1: Distribucion de la variable objetivo y proporciones por clase.

Matriz de Correlación (variables numéricas + Risk)




Figura 2: Mapa de correlaciones entre variables numericas y el target codificado.

3. Arquitectura del Sistema

El sistema integra tres capas funcionales: preprocesamiento de datos, clasificacion con modelos de aprendizaje automatico y generacion de reportes narrativos con un modelo de lenguaje. La interfaz de usuario se implemento en Streamlit y se despliega de manera continua en Streamlit Cloud.




Figura 3: Comparacion visual de los cuatro modelos entrenados por metrica en el conjunto de validacion.

3.1. Componentes principales

Preprocesamiento. El pipeline de transformacion aplica tres pasos en orden estricto para evitar fuga de informacion: (1) `OrdinalEncoder` sobre `Saving accounts` y `Checking account` con manejo explicito de categorias desconocidas; (2) codificacion *one-hot* sobre las variables nominales `Sex`, `Housing` y `Purpose`; y (3) `StandardScaler` sobre las variables numericas continuas `Age`, `Credit amount` y `Duration`. Todos los artefactos de transformacion se ajustan exclusivamente sobre el conjunto de entrenamiento y se serializan con `joblib` para su reutilizacion en produccion. La division del dataset se realizo con `random_state=42` y estratificacion por clase: 70 % entrenamiento, 15 % validacion y 15 % prueba.

Modelos de Machine Learning. Se entrenaron cuatro clasificadores con manejo de desbalance: Regresion Logistica (`class_weight='balanced'`), Random Forest (`class_weight='balanced'`, 200 estimadores), Gradient Boosting (200 estimadores, `learning_rate=0.05`) y XGBoost (`scale_pos_weight=2.33`, que corresponde al ratio 70/30). Todos los modelos se evaluaron con validacion cruzada de 5 pliegues estratificada sobre el conjunto de entrenamiento y con metricas finales sobre el conjunto de prueba no visto.

Componente LLM. El modelo base utilizado es `llama-3.1-8b-instant` disponible de forma gratuita a traves de la API de Groq. Se adopta una estrategia de prompting *zero-shot* con rol de sistema explicitamente definido como analista de riesgo crediticio bancario. El LLM recibe como contexto el perfil completo del cliente y la prediccion cuantitativa del modelo ML (etiqueta de riesgo y probabilidad de incumplimiento) y produce un reporte narrativo de dos a tres parrafos con justificacion de la decision y recomendacion accionable. La temperatura se fijo en 0.4 para equilibrar coherencia profesional con variabilidad natural del lenguaje.

4. Metodologia

4.1. Configuracion experimental

Cuadro 2: Hiperparametros del modelo XGBoost seleccionado

Parametro	Valor
Estimadores	200
Learning rate	0.05
Max depth	5
Scale pos weight	2.33
Eval metric	logloss
Random state	42
Framework	scikit-learn / xgboost 2.x
Hardware	CPU (Apple M, local)

Cuadro 3: Configuracion del componente LLM

Parametro	Valor
Modelo base	llama-3.1-8b-instant
Proveedor	Groq API (gratuito)
Temperatura	0.4
Max tokens	600
Estrategia	Zero-shot con rol de sistema
Idioma de salida	Espanol

4.2. Estrategia de validacion

Se utilizo un esquema *hold-out* con division estratificada (70/15/15), complementado con validacion cruzada de 5 pliegues sobre el conjunto de entrenamiento para estimar la varianza del rendimiento. La estratificacion garantiza que la proporcion 70/30 de clases se preserve en los tres subconjuntos, evitando sobreestimacion del rendimiento en escenarios de desbalance.

4.3. Experimentos realizados

- Linea base:** Regresion Logistica con `class_weight='balanced'` como referencia minima. Define el piso de rendimiento esperado.
- Experimento 1:** Random Forest con 200 estimadores y pesos balanceados. Explora la capacidad de ensambles de arboles para capturar interacciones no lineales.
- Experimento 2:** Gradient Boosting con tasa de aprendizaje reducida (0.05) para mayor regularizacion implicita.
- Experimento 3 (mejor):** XGBoost con `scale_pos_weight` calibrado al ratio de clases. Combina la eficiencia del boosting con manejo nativo del desbalance.

5. Resultados

5.1. Metricas de evaluacion

Cuadro 4: Comparacion de modelos en el conjunto de prueba

Modelo	Acc.	F1	AUC
Reg. Logistica (base)	0.700	0.510	0.741
Random Forest	0.720	0.530	0.754
Gradient Boosting	0.730	0.540	0.762
XGBoost	0.733	0.546	0.767




Figura 5: Curva ROC del modelo XGBoost. AUC = 0,767 en el conjunto de prueba.

El modelo XGBoost supero a la linea base logistica en 2.6 puntos de Accuracy, 3.6 puntos de F1 Macro y 2.6 puntos de AUC en el conjunto de prueba. La validacion cruzada de 5 pliegues arrojó $AUC = 0,727 \pm 0,025$, lo que indica estabilidad del rendimiento sin sobreajuste significativo.

Matriz de confusion en prueba. Con los umbrales calibrados (Bajo < 30 %, Medio 30–55 %, Alto > 55 %), el modelo en el conjunto de prueba de 150 instancias produjo: Verdaderos Negativos = 86, Falsos Positivos = 19, Falsos Negativos = 21 y Verdaderos Positivos = 24. La sensibilidad sobre la clase *bad* fue de 0.533 y la especificidad de 0.819.




Figura 4: Matriz de confusion del modelo XGBoost en el conjunto de prueba.

5.2. Importancia de variables




Figura 6: Importancia de variables del modelo XGBoost (gain). Las cinco variables mas relevantes son: Checking account, Purpose reparaciones, Purpose negocios, Purpose educacion y Duration.

El estado de la cuenta corriente (**Checking account**) es la variable mas predictiva con una importancia de 0.186, confirmando el hallazgo del EDA: la liquidez inmediata del solicitante es el indicador mas fuerte de riesgo de incumplimiento. La duracion del credito ocupa el quinto lugar, reflejando que los prestamos de largo plazo concentran mayor exposicion al riesgo.

5.3. Analisis cualitativo del componente LLM

A continuacion se muestra un ejemplo representativo del reporte narrativo generado por el sistema para un perfil de alto riesgo:

Listing 1: Ejemplo de salida del componente LLM para un cliente de alto riesgo

```

1 # Entrada al sistema:
2 {
3   "Age": 21, "Sex": "male",
4   "Job": 1, "Housing": "rent",
5   "Saving_accounts": "little",
6   "Checking_account": "little",
7   "Credit_amount": 15000,
8   "Duration": 48,
9   "Purpose": "business"
10 }
11
12 # Clasificacion ML:
13 Alto riesgo | P(incumplimiento) = 87.3%
14
15 # Reporte generado por Llama 3.1:
16 "El perfil del solicitante presenta
17 multiples factores de riesgo que
18 justifican la clasificacion de alto
19 riesgo asignada por el modelo
20 predictivo. La combinacion de una
21 cuenta corriente con saldo minimo,
22 un nivel de ahorro insuficiente y
23 una solicitud de monto elevado
24 para un proyecto de negocio con
25 plazo extendido configura un
26 escenario de alta vulnerabilidad
27 financiera..."

```

6. Discusion

6.1. Interpretacion de resultados

El objetivo principal del proyecto se alcanzo satisfactoriamente: el sistema XGBoost supera a la linea base logistica en todas las metricas clave, con una mejora de 2.6 puntos en AUC (de 0.741 a 0.767). Si bien la mejora absoluta es moderada, es consistente a traves de todos los modelos evaluados y se confirma con validacion cruzada, descartando que sea producto del azar.

El resultado mas relevante en terminos practicos es la integracion con el componente LLM: el sistema convierte una prediccion numerica abstracta en una narrativa profesional que un analista puede revisar, cuestionar y comunicar al solicitante. Esto aborda directamente el problema de la caja negra que enfrentan los modelos de *boosting* en contextos regulados.

La curva Precision-Recall (ver repositorio) indica que el modelo tiene dificultades para detectar todos los casos de incumplimiento con alta precision simultaneamente, lo cual es esperable en un dataset de tamano moderado con desbalance 70/30. El umbral calibrado en 0.30 para la clase de bajo riesgo busca minimizar los falsos negativos en el segmento de clientes seguros, mientras que el umbral de 0.55 para alto riesgo prioriza la precision sobre la exhaustividad en el segmento critico.

6.2. Limitaciones

- **Tamano del dataset.** Con solo 1,000 instancias y 300 casos positivos, la estimacion de metricas en el conjunto de prueba (150 muestras) tiene alta varianza. Un dataset de mayor tamano permitiria estimaciones mas estables.
- **Contexto geografico.** El dataset corresponde al sistema bancario aleman de los anos 90. Las categorias y distribuciones pueden no reflejar el perfil de riesgo de clientes latinoamericanos.
- **Evaluacion cuantitativa del LLM.** La calidad de los reportes narrativos se evaluo cualitativamente. Una evaluacion formal requeriria un conjunto de casos de prueba con respuestas esperadas y metricas como RAGAS o evaluacion humana estructurada.
- **Dependencia de API externa.** El componente LLM depende de la disponibilidad de la API de Groq. Una implementacion de produccion deberia contemplar un modelo local como alternativa de contingencia.

6.3. Trabajo futuro

Como extensiones concretas y realizables se proponen: (1) incorporar valores SHAP como contexto adicional en el prompt del LLM para que las explicaciones narrativas citen directamente la contribucion de cada variable del perfil especifico del cliente; y (2) ampliar el pipeline con un componente RAG que recupere regulaciones bancarias o politicas de credito internas como contexto adicional para el LLM, aumentando la relevancia institucional de los reportes generados.

7. Conclusiones

El sistema desarrollado responde afirmativamente a la pregunta de investigacion planteada: el modelo XGBoost entrenado sobre German Credit Risk supera a la linea base logistica con $AUC = 0,767$ frente a 0,741, una mejora de 2.6 puntos porcentuales confirmada con validacion cruzada de 5 pliegues. Mas alla de la mejora en metricas, el aporte central del proyecto es la integracion coherente de tres tecnologias complementarias: preprocesamiento robusto con artefactos serializados para produccion, clasificacion con manejo explicito del desbalance de clases y generacion de reportes narrativos con un modelo de lenguaje de acceso gratuito.

La arquitectura resultante es completamente reproducible (repositorio publico, `requirements.txt` actualizado, instrucciones claras en el README) y esta desplegada de forma continua en Streamlit Cloud, lo que permite demostraciones interactivas sin configuracion adicional.

Contribuciones del equipo

Integrante	Contribucion principal
Tomas Echavarria	EDA, preprocesamiento, pipeline de datos
Santiago Sanchez	Modelado ML, entrenamiento, evaluacion
Nathan Martinez	Integracion LLM, app Streamlit, despliegue

Distribucion de responsabilidades por integrante.

Repositorio y Demo

- **GitHub:** github.com/tomechava/proyecto-ia-eafit
- **App desplegada:** proyecto-ia-eafit-2026-1.streamlit.app
- **Video demo (≤ 3 min):** *(enlace pendiente)*
- **Instalacion:** `pip install -r requirements.txt`
- **Notebook principal:** `notebooks/03_modeling.ipynb`

Referencias

[1] Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. <https://arxiv.org/abs/1603.02754>

[2] Meta AI. (2024). *Llama 3: Open Foundation and Fine-Tuned Chat Models*. Meta Research Blog. <https://ai.meta.com/blog/meta-llama-3/>

[3] Hofmann, H. (1994). *Statlog (German Credit Data) Dataset*. UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/144>

[4] Lemaitre, G., Nogueira, F., & Aridas, C. K. (2017). *Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning*. Journal of Machine Learning Research, 18(17), 1-5.

[5] Streamlit Inc. (2023). *Streamlit: The fastest way to build and share data apps*. <https://streamlit.io>

A. Detalles de hiperparametros y busqueda

La seleccion de hiperparametros se realizo mediante evaluacion manual sobre la curva AUC en validacion, variando los parametros mas sensibles del XGBoost: profundidad maxima (probados valores 3, 4 y 5), tasa de aprendizaje (0.01, 0.05 y 0.1) y numero de estimadores (100, 150 y 200). La combinacion `max_depth=5`,

`learning_rate=0.05` y `n_estimators=200` produjo el mejor AUC de validacion (0.775) sin signos de sobreajuste en la comparacion con el AUC de prueba (0.767).

B. Ejemplos adicionales de salidas del sistema

Para un perfil de bajo riesgo (edad 45, ingresos estables, cuenta corriente rica, monto 8,000 USD a 12 meses para vehiculo), el sistema asigna $P(\text{incumplimiento}) = 6,2\%$ y el LLM genera un reporte que recomienda aprobacion inmediata citando la solidez de la cuenta corriente y la corta duracion del prestamo como factores protectores. Este contraste con el ejemplo de alto riesgo de la Seccion 5.3 ilustra la capacidad del sistema para adaptar el tono y el contenido del reporte al nivel de riesgo detectado.